



Universidad Nacional Autónoma de México  
Facultad de Ciencias

Tarea 2

Modelos No Paramétricos y de Regresión  
Semestre 2023 - 2

Ruth Selene Fuentes García  
Jorge Iván Reyes Hernández

---

Alumno: Olvera Trejo Alberto

---

## 1. Ejercicios

**Ejercicio 1.** Considera el modelo lineal simple:  $Y_i = \beta_0 + \beta_1 X_i + e_i$ , muestra que:

a)  $\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i$

b)  $\sum_{i=1}^n r_i X_i = 0$

c)  $\sum_{i=1}^n r_i \hat{Y}_i = 0$

d) La línea de regresión pasa por el punto  $(\bar{X}, \bar{Y})$ ,

donde  $r_i = Y_i - \hat{Y}_i$

*Demostración.* Recordemos que:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

a)

$$\begin{aligned} \sum_{i=1}^n \hat{Y}_i &= \sum_{i=1}^n \hat{\beta}_0 + \hat{\beta}_1 X_i \\ &= n\hat{\beta}_0 + \hat{\beta}_1 \bar{X} \\ &= n(\bar{Y} - \hat{\beta}_1 \bar{X}) + n\bar{X} \frac{S_{xy}}{S_{xx}} \end{aligned}$$

Sustituyendo  $\hat{\beta}_1$ :

$$\begin{aligned}
\sum_{i=1}^n \hat{Y}_i &= n \left( \bar{Y} - \hat{\beta}_1 \bar{X} \right) + n \bar{X} \frac{S_{xy}}{S_{xx}} \\
&= n \left( \bar{Y} - \frac{S_{xy}}{S_{xx}} \bar{X} \right) + n \bar{X} \frac{S_{xy}}{S_{xx}} \\
&= n \bar{Y} - n \bar{X} \frac{S_{xy}}{S_{xx}} + n \bar{X} \frac{S_{xy}}{S_{xx}} \\
&= n \bar{Y} = \sum_{i=1}^n Y_i
\end{aligned}$$

Por lo tanto  $\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i$

b) Recordemos que:

$$S_{xx} = \sum_{i=1}^n X_i^2 - n \bar{X}^2 \quad S_{xy} = \sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y}$$

Luego, sustituyendo  $r_i, \hat{\beta}_0$  y  $\hat{\beta}_1$ :

$$\begin{aligned}
\sum_{i=1}^n r_i X_i &= \sum_{i=1}^n (Y_i - \hat{Y}_i) X_i \\
&= \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) X_i \\
&= \sum_{i=1}^n (Y_i - (\bar{Y} - \hat{\beta}_1 \bar{X}) - \hat{\beta}_1 X_i) X_i \\
&= \sum_{i=1}^n (Y_i - \bar{Y} + \hat{\beta}_1 (\bar{X} - X_i)) X_i \\
&= \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n X_i \bar{Y} + \hat{\beta}_1 \sum_{i=1}^n X_i (\bar{X} - X_i) \\
&= \sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y} + \hat{\beta}_1 \sum_{i=1}^n (X_i \bar{X} - X_i^2) \\
&= S_{xy} - \frac{S_{xy}}{S_{xx}} \sum_{i=1}^n (X_i^2 - X_i \bar{X}) \\
&= S_{xy} - \frac{S_{xy}}{S_{xx}} \left( \sum_{i=1}^n X_i^2 - n \bar{X}^2 \right) \\
&= S_{xy} - \frac{S_{xy}}{S_{xx}} S_{xx} \\
&= S_{xy} - S_{xy} = 0
\end{aligned}$$

Por lo tanto  $\sum_{i=1}^n r_i X_i = 0$

c) Por el inciso a) tenemos que  $\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i$ , por lo que:

$$0 = \sum_{i=1}^n Y_i - \hat{Y}_i = \sum_{i=1}^n r_i$$

Por lo tanto  $\sum_{i=1}^n r_i = 0$ . Así, usando este resultado y el inciso anterior tenemos:

$$\begin{aligned} \sum_{i=1}^n r_i \hat{Y}_i &= \sum_{i=1}^n r_i (\hat{\beta}_0 + \hat{\beta}_1 X_i) \\ &= \hat{\beta}_0 \sum_{i=1}^n r_i + \hat{\beta}_1 \sum_{i=1}^n r_i X_i \\ &= \hat{\beta}_0 \cdot 0 + \hat{\beta}_1 \cdot 0 = 0 \end{aligned}$$

Por lo tanto  $\sum_{i=1}^n r_i \hat{Y}_i = 0$

d) Veamos que la línea pasa por  $(\bar{X}, \bar{Y})$ , para ello basta ver que dicho punto satisface la ecuación  $Y = \hat{\beta}_0 + \hat{\beta}_1 X$ .

Sustituyendo  $\bar{X}$  por  $X$  y reescribiendo los estimadores tenemos:

$$\begin{aligned} Y &= \hat{\beta}_0 + \hat{\beta}_1 \bar{X} \\ &= \bar{Y} - \hat{\beta}_1 \bar{X} + \hat{\beta}_1 \bar{X} \\ &= \bar{Y} \end{aligned}$$

Por lo tanto, la recta de regresión pasa por el punto  $(\bar{X}, \bar{Y})$

**QED**

**Ejercicio 2.** Para el modelo  $Y_i = \beta_0 + \beta_1 (X_i - \bar{X}) + e_i$ ,  $i = 1, \dots, n$  con las hipótesis usuales:

- Obtén los estimadores máximo verosímiles para  $\beta_0$  y  $\beta_1$
- Demuestra que en este caso los estimadores  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son independientes
- Obten la distribución de  $\hat{\beta}_0$  y  $\hat{\beta}_1$
- Obten un intervalo de confianza para el valor esperado de  $Y$  cuando  $X = X_0$

Solución.

a) Sabemos que  $e_i \sim N(0, \sigma^2)$ , y como cada  $Y_i$  es un desplazamiento de las v.a.  $e_i$ , entonces se sigue que las  $Y_i$  son normales. Vamos a calcular su esperanza y su varianza:

$$\mathbb{E}[Y_i] = \mathbb{E}[\beta_0 + \beta_1 (X_i - \bar{X}) + e_i] = \beta_0 + \beta_1 (X_i - \bar{X})$$

$$\text{Var}(Y_i) = \text{Var}(\beta_0 + \beta_1 (X_i - \bar{X}) + e_i) = \text{Var}(e_i) = \sigma^2$$

Así, tenemos que  $Y_i \sim N(\beta_0 + \beta_1 (X_i - \bar{X}), \sigma^2)$ . Más aun, como los errores  $e_i$  son independientes entre sí, entonces las  $Y_i$  son también independientes entre sí.

Para poder calcular lo EMV necesitamos la función de verosimilitud. Usando la independencia de las  $Y_i$  tenemos que:

$$\begin{aligned} \mathcal{L}(\beta_0, \beta_1 | \underline{X}, \underline{Y}) &= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp\left(-\frac{(Y_i - \beta_0 - \beta_1 (X_i - \bar{X}))^2}{2\sigma^2}\right) \\ &= (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 (X_i - \bar{X}))^2\right) \end{aligned}$$

Ahora calculamos el ln de la función de verosimilitud:

$$\ln(\mathcal{L}(\beta_0, \beta_1 | \underline{X}, \underline{Y})) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 (X_i - \bar{X}))^2$$

Derivando respecto a  $\beta_0$  y  $\beta_1$ :

$$\begin{aligned} \blacksquare \frac{\partial}{\partial \beta_0} \ln(\mathcal{L}(\beta_0, \beta_1 | \underline{X}, \underline{Y})) &= \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 (X_i - \bar{X})) \\ \blacksquare \frac{\partial}{\partial \beta_1} \ln(\mathcal{L}(\beta_0, \beta_1 | \underline{X}, \underline{Y})) &= \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 (X_i - \bar{X})) (X_i - \bar{X}) \end{aligned}$$

Tomemos la primera ecuación e igualémosla a cero:

$$\begin{aligned} 0 &= \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 (X_i - \bar{X})) \\ 0 &= \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 (X_i - \bar{X})) \\ 0 &= n\bar{Y} - n\beta_0 - \beta_1 \sum_{i=1}^n (X_i - \bar{X}) \\ 0 &= n\bar{Y} - n\beta_0 - \beta_1 (n\bar{X} - n\bar{X}) \\ 0 &= n\bar{Y} - n\beta_0 \\ 0 &= \bar{Y} - \beta_0 \end{aligned}$$

Entonces, despejando  $\beta_0$  llegamos a que  $\hat{\beta}_0 = \bar{Y}$

Ahora hacemos lo análogo pero con la derivada parcial respecto a  $\beta_1$

$$\begin{aligned}
0 &= \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 (X_i - \bar{X})) (X_i - \bar{X}) \\
0 &= \sum_{i=1}^n ((Y_i - \beta_0) - \beta_1 (X_i - \bar{X})) (X_i - \bar{X}) \\
0 &= \sum_{i=1}^n (Y_i - \beta_0) (X_i - \bar{X}) - \beta_1 \sum_{i=1}^n (X_i - \bar{X})^2 \\
0 &= \sum_{i=1}^n (Y_i - \beta_0) (X_i - \bar{X}) - \beta_1 \sum_{i=1}^n (X_i - \bar{X})^2 \\
0 &= \sum_{i=1}^n (Y_i - \hat{\beta}_0) (X_i - \bar{X}) - \beta_1 S_{xx} \\
0 &= \sum_{i=1}^n (Y_i - \bar{Y}) (X_i - \bar{X}) - \beta_1 S_{xx} \\
0 &= S_{xy} - \beta_1 S_{xx}
\end{aligned}$$

Despejando  $\beta_1$  tenemos que  $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$ .

Por lo tanto, los EMV son:

$$\hat{\beta}_0 = \bar{Y} \quad \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

b) Para ver que  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son independientes, basta ver que su covarianza es cero. Recordemos que por lo visto en clase:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \sum_{i=1}^n \frac{X_i - \bar{X}}{S_{xx}} Y_i = \sum_{i=1}^n c_i Y_i,$$

donde  $c_i = \frac{X_i - \bar{X}}{S_{xx}}$  y además sabemos que (igualmente por lo visto en clase)  $\sum_{i=1}^n c_i = 0$ . Usando lo anterior, las propiedades de la covarianza y que las  $Y_i$  son independientes:

$$\begin{aligned}
Cov(\hat{\beta}_0, \hat{\beta}_1) &= Cov\left(\bar{Y}, \sum_{i=1}^n c_i Y_i\right) \\
&= \sum_{i=1}^n c_i \cdot Cov(\bar{Y}, Y_i) \\
&= \sum_{i=1}^n c_i \cdot Cov\left(\frac{1}{n} \sum_{j=1}^n Y_j, Y_i\right) \\
&= \sum_{i=1}^n \sum_{j=1}^n \frac{c_i}{n} Cov(Y_j, Y_i) \\
&= \sum_{i=1}^n \sum_{j=1}^n \frac{c_i}{n} \delta_{ji} \sigma^2 \\
&= \sum_{i=1}^n \frac{c_i}{n} \sigma^2 = \frac{\sigma^2}{n} \sum_{i=1}^n c_i = \frac{\sigma^2}{n} \cdot 0 = 0
\end{aligned}$$

Por lo tanto  $Cov(\hat{\beta}_0, \hat{\beta}_1) = 0$  y concluimos que los estimadores son independientes.

- c) Primero vamos a obtener la distribución de  $\hat{\beta}_0$ . Como  $Y_i \sim N(\beta_0 + \beta_1(X_i - \bar{X}), \sigma^2)$ , entonces  $\bar{Y}$  es una normal, por ser suma de normales. Vamos a calcular sus parámetros:

$$\begin{aligned}\mathbb{E}[\bar{Y}] &= \mathbb{E}\left[\sum_{i=1}^n \frac{Y_i}{n}\right] \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[Y_i] \\ &= \frac{1}{n} \sum_{i=1}^n (\beta_0 + \beta_1(X_i - \bar{X})) \\ &= \frac{1}{n} \left( n\beta_0 + \beta_1 \sum_{i=1}^n (X_i - \bar{X}) \right) \\ &= \frac{1}{n} (n\beta_0 + \beta_1(n\bar{X} - n\bar{X})) \\ &= \frac{n\beta_0}{n} = \beta_0\end{aligned}$$

Por lo tanto  $\mathbb{E}[\hat{\beta}_0] = \beta_0$ .

Análogamente calculamos la varianza, tomando en cuenta que las  $Y_i$  son independientes entre sí.

$$\begin{aligned}Var(\hat{\beta}_0) &= Var(\bar{Y}) \\ &= Var\left(\sum_{i=1}^n \frac{Y_i}{n}\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n Var(Y_i) \\ &= \frac{1}{n^2} \sum_{i=1}^n \sigma^2 \\ &= \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}\end{aligned}$$

Por lo tanto  $\hat{\beta}_0 \sim N(\beta_0, \frac{\sigma^2}{n})$ .

Ahora hacemos lo mismo pero con  $\hat{\beta}_1$  recordando que  $\hat{\beta}_1 = \sum_{i=1}^n c_i Y_i$ , con  $c_i = \frac{X_i - \bar{X}}{S_{xx}}$  y que  $\sum_{i=1}^n c_i = 0$

$$\begin{aligned}\mathbb{E}[\hat{\beta}_1] &= \mathbb{E}\left[\sum_{i=1}^n c_i Y_i\right] \\ &= \sum_{i=1}^n c_i \mathbb{E}[Y_i] \\ &= \sum_{i=1}^n c_i (\beta_0 + \beta_1(X_i - \bar{X})) \\ &= \beta_0 \sum_{i=1}^n c_i + \beta_1 \sum_{i=1}^n c_i (X_i - \bar{X})\end{aligned}$$

$$\begin{aligned}
\mathbb{E}[\hat{\beta}_1] &= \beta_0 \sum_{i=1}^n c_i + \beta_1 \sum_{i=1}^n c_i (X_i - \bar{X}) \\
&= \beta_0 \cdot 0 + \beta_1 \sum_{i=1}^n \frac{(X_i - \bar{X})}{S_{xx}} (X_i - \bar{X}) \\
&= \frac{\beta_1}{S_{xx}} \sum_{i=1}^n (X_i - \bar{X}) \\
&= \frac{\beta_1}{S_{xx}} S_{xx} = \beta_1
\end{aligned}$$

Entonces  $\mathbb{E}[\hat{\beta}_1] = \beta_1$ . Ahora la varianza:

$$\begin{aligned}
Var(\hat{\beta}_1) &= Var\left(\sum_{i=1}^n c_i Y_i\right) \\
&= \sum_{i=1}^n c_i^2 Var(Y_i) \\
&= \sum_{i=1}^n c_i^2 \sigma^2 \\
&= \frac{\sigma^2}{S_{xx}^2} \sum_{i=1}^n (X_i - \bar{X})^2 \\
&= \frac{\sigma^2}{S_{xx}^2} S_{xx} = \frac{\sigma^2}{S_{xx}}
\end{aligned}$$

Entonces  $Var(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$ . Así, concluimos que:

$$\hat{\beta}_0 \sim N\left(\beta_0, \frac{\sigma^2}{n}\right) \quad \hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right) \quad (1)$$

- d) Buscamos un intervalo de confianza para el valor esperado de  $Y$  cuando  $X = X_0$ . Supondremos que  $X_0$  es un punto que se encuentra dentro del intervalo definido por los valores  $x$  que se usaron para ajustar el modelo. Notamos que un estimador insesgado para  $\mathbb{E}[y|x_0]$  es:

$$\widehat{\mathbb{E}[y|x_0]} = \hat{\beta}_0 + \hat{\beta}_1 x_0 \quad (2)$$

Vamos a calcular un intervalo del  $100(1 - \alpha)$  de confianza. Como  $\hat{\beta}_1$  y  $\hat{\beta}_2$  son normales, entonces el estimador (2) se distribuye también de forma normal por ser una combinación lineal de  $\hat{\beta}_1$  y  $\hat{\beta}_2$ . Vamos a calcular la varianza recordando que  $Cov(\hat{\beta}_1, \hat{\beta}_0) = 0$

$$\begin{aligned}
Var\left(\widehat{\mathbb{E}[y|x_0]}\right) &= Var(\hat{\beta}_0 + \hat{\beta}_1 x_0) \\
&= Var(\hat{\beta}_0) + x_0^2 Var(\hat{\beta}_1)
\end{aligned}$$

Sustituimos las varianzas usando (1)

$$\text{Var} \left( \widehat{\mathbb{E}[y|x_0]} \right) = \frac{\sigma^2}{n} + x_0^2 \frac{\sigma^2}{S_{xx}} = \sigma^2 \left( \frac{1}{n} + \frac{x_0^2}{S_{xx}} \right)$$

Así, tenemos que:

$$Z = \frac{\widehat{\mathbb{E}[y|x_0]} - \mathbb{E}[y|x_0]}{\sqrt{\sigma^2 \left( \frac{1}{n} + \frac{x_0^2}{S_{xx}} \right)}} \sim N(0, 1) \quad (3)$$

Luego, por lo visto en clase sabemos que  $\frac{SSE}{n-2} = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$  es un estimador insesgado para  $\sigma^2$  y además  $\frac{n-2}{\sigma^2} \cdot \frac{SSE}{n-2} = \frac{SSE}{\sigma^2} \sim \chi^2_{(n-2)}$

$$\chi^2 = \frac{SSE}{\sigma^2} \sim \chi^2_{(n-2)} \quad (4)$$

Entonces, usando (3), (4) y resultados de proba II de transformación de variables tenemos que  $\frac{Z}{\sqrt{\chi^2/(n-2)}} \sim t_{(n-2)}$ . Desarrollando la expresión anterior:

$$\begin{aligned} \frac{Z}{\sqrt{\chi^2/(n-2)}} &= \frac{\frac{\widehat{\mathbb{E}[y|x_0]} - \mathbb{E}[y|x_0]}{\sqrt{\sigma^2 \left( \frac{1}{n} + \frac{x_0^2}{S_{xx}} \right)}}}{\sqrt{SSE/\sigma^2(n-2)}} \\ &= \frac{\widehat{\mathbb{E}[y|x_0]} - \mathbb{E}[y|x_0]}{\sqrt{\frac{SSE}{n-2} \left( \frac{1}{n} + \frac{x_0^2}{S_{xx}} \right)}} \end{aligned}$$

Notamos que podemos usar  $\frac{\widehat{\mathbb{E}[y|x_0]} - \mathbb{E}[y|x_0]}{\sqrt{\frac{SSE}{n-2} \left( \frac{1}{n} + \frac{x_0^2}{S_{xx}} \right)}}$  como cantidad pivotal. Sea  $t_{1-\alpha/2, n-2}$  el cuantil  $1-\alpha/2$  de una  $t$ -Student con  $n-2$  grados de libertad, entonces el intervalo del  $100(1-\alpha)$  de confianza es:

$$\left( \widehat{\mathbb{E}[y|x_0]} - t_{1-\alpha/2, n-2} \sqrt{\frac{SSE}{n-2} \left( \frac{1}{n} + \frac{x_0^2}{S_{xx}} \right)}, \widehat{\mathbb{E}[y|x_0]} + t_{1-\alpha/2, n-2} \sqrt{\frac{SSE}{n-2} \left( \frac{1}{n} + \frac{x_0^2}{S_{xx}} \right)} \leq \mathbb{E}[y|x_0] \right)$$

**Ejercicio 3.** En el modelo lineal simple  $Y_i = \beta_0 + \beta_1 X_i + e_i$ , con las hipótesis usuales, muestra que la prueba de hipótesis que se obtiene del cociente de verosimilitudes generalizado para probar

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{vs} \quad H_a : \beta_1 \neq \beta_{1,0}$$

con  $\beta_{1,0}$  una constante conocida, depende de una estadística  $T$  que tiene una distribución  $t$ -Student y encuentre la región de rechazo.



*Demostración.* Calculemos la estadística usando el cociente de verosimilitudes generalizado. Primero notemos que el espacio parametral es:

$$\Theta = \{(\beta_0, \beta_1, \sigma^2) : \beta_0, \beta_1 \in \mathbb{R}, \sigma^2 > 0\}$$

Y el espacio parametral bajo  $H_0$  es:

$$\Theta_0 = \{(\beta_0, \beta_1, \sigma^2) : \beta_1 = \beta_{1,0}, \beta_0 \in \mathbb{R}, \sigma^2 > 0\}$$

Por otro lado, la función de verosimilitud es:

$$\mathcal{L}(\beta_0, \beta_1, \sigma^2 | \underline{X}, \underline{Y}) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - (\beta_0 - \beta_1 X_1))^2\right)$$

Entonces, para obtener el numerador del cociente tomemos  $(\beta_0, \beta_1, \sigma^2) \in \Theta_0$  y tenemos que:

$$\mathcal{L}(\beta_0, \beta_1, \sigma^2 | \underline{X}, \underline{Y}) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - (\beta_0 - \beta_{1,0} X_1))^2\right)$$

Ahora maximizamos la función anterior sacando el logaritmo, derivando respecto a  $\sigma^2$ , igualando a cero y resolviendo para  $\sigma^2$ :

$$\ln(\mathcal{L}(\beta_0, \beta_1, \sigma^2 | \underline{X})) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - (\beta_0 - \beta_{1,0} X_1))^2$$

Derivando:

$$\frac{\partial}{\partial \beta_0} \ln(\mathcal{L}(\beta_0, \beta_1, \sigma^2 | \underline{X})) = \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - (\beta_0 - \beta_{1,0} X_1)) = 0$$

Entonces:

$$\begin{aligned} 0 &= \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - (\beta_0 - \beta_{1,0} X_1)) \\ 0 &= n\bar{Y} - n\beta_0 - n\beta_{1,0}\bar{X} \\ 0 &= \bar{Y} - \beta_0 - \beta_{1,0}\bar{X} \end{aligned}$$

Por lo tanto  $\hat{\beta}_0 = \bar{Y} - \beta_{1,0}\bar{X}$

Análogamente con  $\sigma^2$

$$\frac{\partial}{\partial \sigma^2} \ln(\mathcal{L}(\beta_0, \beta_1, \sigma^2 | \underline{X})) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n X_i^2 = 0$$

Resolviendo para  $\sigma^2$ :

$$\begin{aligned} 0 &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (Y_i - (\beta_0 - \beta_{1,0} X_1))^2 \\ 0 &= -n\sigma^2 + \sum_{i=1}^n (Y_i - (\beta_0 - \beta_{1,0} X_1))^2 \\ n\sigma^2 &= \sum_{i=1}^n (Y_i - (\beta_0 - \beta_{1,0} X_1))^2 \\ \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (Y_i - (\beta_0 - \beta_{1,0} X_1))^2 \end{aligned}$$

Entonces  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \left( Y_i - (\hat{\beta}_0 - \beta_{1,0} X_1) \right)^2$ , por lo que:

$$\begin{aligned} \max_{(\beta_0, \beta_1, \sigma^2) \in \Theta_0} \mathcal{L}(\mu, \sigma^2 | \underline{X}, \underline{Y}) &= (2\pi\hat{\sigma}^2)^{-n/2} \exp \left( -\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n \left( Y_i - (\hat{\beta}_0 + \beta_{1,0} X_i) \right)^2 \right) \\ &= (2\pi\hat{\sigma}^2)^{-n/2} \exp(-n/2) \end{aligned}$$

Por lo tanto, el numerador es  $(2\pi\hat{\sigma}^2)^{-n/2} \exp(-n/2)$ .

Por otro lado, sabemos que los EMV son:

$$\widehat{\beta_{1ML}} = \frac{S_{xy}}{S_{xx}} \quad \widehat{\beta_{0ML}} = \bar{Y} - \hat{\beta}_1 \bar{X} \quad \widehat{\sigma_{ML}^2} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Entonces:

$$\begin{aligned} \max_{(\beta_0, \beta_1, \sigma^2) \in \Theta} \mathcal{L}(\mu, \sigma^2 | \underline{X}, \underline{Y}) &= (2\pi\widehat{\sigma_{ML}^2})^{-n/2} \exp \left( -\frac{1}{2\widehat{\sigma_{ML}^2}} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \right) \\ &= (2\pi\widehat{\sigma_{ML}^2})^{-n/2} \exp -n/2 \end{aligned}$$

Entonces, el cociente de verosimilitudes generalizado es:

$$\begin{aligned} \Lambda &= \frac{\max_{(\beta_0, \beta_1, \sigma^2) \in \Theta_0} \mathcal{L}(\mu, \sigma^2 | \underline{X}, \underline{Y})}{\max_{(\beta_0, \beta_1, \sigma^2) \in \Theta} \mathcal{L}(\mu, \sigma^2 | \underline{X}, \underline{Y})} = \frac{(2\pi\hat{\sigma}^2)^{-n/2} \exp(-n/2)}{(2\pi\widehat{\sigma_{ML}^2})^{-n/2} \exp -n/2} \\ &= \frac{(\hat{\sigma}^2)^{-n/2}}{(\widehat{\sigma_{ML}^2})^{-n/2}} \\ &= \left( \frac{\frac{1}{n} \sum_{i=1}^n (Y_i - (\hat{\beta}_0 - \beta_{1,0} X_1))^2}{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2} \right)^{-n/2} \\ &= \left( \frac{\sum_{i=1}^n (Y_i - (\hat{\beta}_0 - \beta_{1,0} X_1))^2}{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2} \right)^{-n/2} \\ &= \left( \frac{\sum_{i=1}^n (Y_i - \bar{Y} - \beta_{1,0} (X_i - \bar{X}))^2}{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2} \right)^{-n/2} \\ &= \left( \frac{\sum_{i=1}^n (Y_i - \bar{Y})^2 - 2\beta_{1,0} S_{xy} + \beta_{1,0}^2 S_{xx}}{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2} \right)^{-n/2} \\ &= \left( \frac{S_{yy} - 2\beta_{1,0} S_{xy} + \beta_{1,0}^2 S_{xx}}{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2} \right)^{-n/2} \end{aligned}$$

Así, dividiendo entre  $S_{xx}$  tenemos que:

$$\begin{aligned}\Lambda &= \left( \frac{S_{yy}/S_{xx} - 2\beta_{1,0}S_{xy}/S_{xx} + \beta_{1,0}^2 S_{xx}/S_{xx}}{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2 / S_{xx}} \right)^{-n/2} \\ &= \left( \frac{S_{yy}/S_{xx} - 2\beta_{1,0}\hat{\beta}_{1ML} + \beta_{1,0}^2}{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2 / S_{xx}} \right)^{-n/2}\end{aligned}$$

Notamos que  $\frac{(n-2) \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sigma^2} \sim \chi_{(n-2)}^2$  y que  $\frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\sigma^2/S_{xx}}} \sim N(0, 1)$  y haciendo usando el teorema de transformación de una normal y una ji cuadrada:

$$\frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\sum_{i=1}^n (Y_i - \bar{Y}_i)^2 / (n-2) S_{xx}}} \sim t_{(n-2)}$$

Sea  $T = \left( \frac{S_{yy}/S_{xx} - 2\beta_{1,0}\hat{\beta}_{1ML} + \beta_{1,0}^2}{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2 / S_{xx}} \right)^{-n/2}$ . Únicamente resta ver que el numerador es  $(\hat{\beta}_1 - \beta_{10})^2$  para poder llegar al resultado, pero ya no supe cómo :((( **QED**